

Егор Васильев

Data Science · NLP / LLM / RAG

Санкт-Петербург, Россия · vasil3vegor@yandex.ru · Telegram: @Um4to · GitHub: Umato

Студент направления «Науки о данных» СПбГУ. Фокусируюсь на NLP/LLM и retrieval-системах: работал с RAG, hybrid dense+sparse retrieval, reranking и offline evaluation, а также с расширением токенизаторов и инициализацией эмбеддингов новых токенов. Интересуюсь мультимодальными ML-системами и инструментами для образовательного контента.

ОБРАЗОВАНИЕ

Санкт-Петербургский государственный университет (СПбГУ)

ожидаемый выпуск: 2027

Бакалавриат, направление «Науки о данных» | GPA: 4.2/5.0

ПРОЕКТЫ И ОПЫТ

RAG-система для «Сириус.Курсов»

09.2025 - 01.2026

Курсовой проект · retrieval / reranking

- Спроектировал и реализовал retriever-пайплайн: dense и hybrid dense+sparse retrieval в Qdrant, sparse-поиск на BM25, фильтрацию по метаданным и объединение результатов; интеграция с LlamaIndex.
- Реализовал reranking для BGE/Jina/GTE-моделей и динамическую упаковку retrieved chunks под token budget контекста.
- Построил offline evaluation с Hit@k, Recall@k, MRR, nDCG и MAP; сравнивал конфигурации retrieval и улучшал качество поиска без раскрытия внутренних результатов.

Адаптация LLM к арабскому языку

02.2026 - 05.2026

Курсовой проект · tokenization / embeddings · [GitHub](#)

- Исследовал инициализацию эмбеддингов при расширении словаря Qwen3-0.6B примерно на 47k арабских токенов; адаптировал Token Distillation под кастомный токенизатор и staged training.
- Сравнивал subtoken mean, FOCUS и FOCUS + Token Distillation, проводил ablation-эксперименты по слоям, классам токенов и гиперпараметрам; лучшая конфигурация снизила perplexity примерно на 23% относительно FOCUS-only baseline на held-out split.

Летняя школа по NLP

лето 2025

Проект: анализ текстов · офлайн

- Собрал и подготовил текстовый корпус: парсинг, очистка и предобработка данных на Python.
- Проводил эксперименты с TF-IDF и эмбеддингами, кластеризацией и классификацией (логистическая регрессия, SVM); использовал scikit-learn и модели Hugging Face.

ТЕХНИЧЕСКИЕ НАВЫКИ

Язык	Python
ML / NLP / LLM	PyTorch, Hugging Face Transformers/Datasets, Sentence Transformers, scikit-learn, RAG, embeddings, tokenization, retrieval, reranking
Data	pandas, NumPy, matplotlib
Retrieval / БД	Qdrant, LlamaIndex, SQL, PostgreSQL
Инструменты	Git, Docker, Linux, ffmpeg
Математика	линейная алгебра, теория вероятностей, статистика, дискретная математика
Английский	B2